

工作经历

蓝色光标 · 2025.07 - 至今

DSP 投放引擎与预估模型 · 日均 200 亿请求 · 100ms 竞价

- **模型架构**: 从零搭建 CTR/CVR 预估模型, 经历两代架构演进。V1 基于 OneTrans 统一 Tokenizer 将序列与非序列特征编码为同质 token, 单 Causal Transformer 端到端建模; V2 升级为 HyFormer 混合架构(Cross-Attention 序列解码 + MLP-Mixer 特征交互), 多序列独立建模避免合并信息损失, 同等 FLOPs 下 CVR AUC 优于 V1。基于 TensorFlow + Horovod 分布式训练, TFRA 动态 Embedding 处理亿级稀疏 ID。
- **特征工程与校准**: 基于 EDA 量化信号强度(Cohen's d)驱动特征选择——发现 hour_of_day CVR 存在 5 倍方差, 设计 sin/cos 周期编码(离线 AUC +0.26%); 构建 Kafka 实时样本拼接 + 负采样校准 + Isotonic 保序校准, PCOC 从 1.17/1.20 校准至 0.93。CVR 离线 AUC 0.75 → 0.80+ (+6.7%), V3 全量后 eCPM +18%, 广告主 CPA -22%, 日均消耗 +15%。
- **多模型在线服务**: 从零搭建 CTR → CVR → ESMM 多模型推理服务集群并推至上线, 统一模型路由、版本热加载与分数校准; 处理 ESMM 联合概率与条件概率的语义差异, 将两次 RPC 合并为一次, Predictor 复用特征处理器降低多模型并行内存开销。
- **在线特征性能**: 统计特征读取逼近 50ms 预算上限, 剖析定位 gzip 解压占 28ms 为主要瓶颈; 优化解码路径、反序列化与对象复用, 18KB 单键基准耗时从 87.3μs 降至 53.1μs (-39%), 缓存命中率约 65%。
- **竞价引擎与智能出价**: 基于 Go 构建竞价引擎(857+ commits), Pipeline 模式解耦定向/频控/出价/创意, 配置热加载支持策略小时级上线; 支撑国内及海外(美东、新加坡)多地域部署, 峰值 QPS 50w+, P99 < 100ms。设计 K 值自适应 Smart Bidding + PID 预算分配 + Slow Start 冷启动, OCPC 成本达标率 68% → 85%, 预算利用率 85% → 98%, ROI +22%。
- **实验平台**: 补齐实验生命周期管理、CVR 分析与窗口校验, 覆盖 DSP 四区域, 实验周期从 2 周缩至 3 天。

ADX 广告交易平台 · 日均 2000 亿请求

- **Bid Shading 博弈系统**: 针对同客户同媒体出价呈双峰分布导致赢标率偏低的问题, 设计两阶段竞价优化——Stage 1 调用 TFS 模型(50+ 特征)输出赢标概率与计费率(Theta1/Theta2/BillingRate), Stage 2 PID 控制器结合 Alpha 参数和 ROI 约束动态调整出价, 上下界保护确保最终出价在 0.5x~2x 原始出价区间内。支持 DSP × 媒体 × 模板多粒度配置, 11 个 DSP 博弈策略在线运行, A/B 实验分组实时切换。
- **出价链路与定价体系**: 梳理并治理 8 层定价链路——DSP 出价 → 汇率 → 利润率扣减 → DmBid 配价规则 → 博弈模型出价 → 底价补贴 → Floor 保护 → 价格上限安全过滤; 支持固定结算与动态结算两种模式, 按 DSP × Exchange × Template × 广告位四维谓词匹配最优配价规则, 特异度打分解决多规则冲突。
- **CTR 模型动态定价**: 将 CPC 出价从运营手配固定价升级为候选级 pCTR 动态换算(模型 CPC = 净 CPM / pCTR / 1000), 统一 79 项模型输入与候选日志使定价可追溯; 设计定价与排序解耦方案避免低 pCTR 候选获得错误优先级。构建 ADX 实时统计特征管线提供近 N 分钟聚合信号, 弥补模型更新间隔内的意图漂移。首轮灰度定位 pricing_mode 语义 bug, 通过约 8 万次受控 A/A 核实验证链路。
- **流量治理与经营诊断**: 设计 7 级流量优先级体系(白名单 → 高 RPM → 新流量探测), 基于 RPM 的 QPS 限流与黑名单机制实时调控变现效率。补查 21 个遗漏 DSP 将收入分析覆盖率从 93.72% 补齐至约 100%, 识别 89 个返点后负利润组合; 将 RPM 监控、流量诊断等 6 类重复任务封装为可执行工具。

advoo.ai · Agent 执行引擎与业务工具平台 · Go + React · 面向中小品牌

- **Agent 执行引擎**: 设计 SSE 三协程流水线(调度/执行/推送)驱动 Agent Loop, 支持最多 64 轮自主推演与中断恢复; 实现 Prepare/Run 二阶段 Session 状态机, 管理从品牌选择到内容生成到跨渠道发布的完整任务生命周期。
- **工具系统**: 构建 10+ Agent 工具集(Bash 执行、文件 CRUD、网页检索与抓取、图片编辑与生成、视频生成、任务调度、会话历史), 设计双输出模型(工具结果 + 用户可见摘要)与中断语义, 使 Agent 在工具调用失败时能优雅降级而非中断整个任务链。
- **Brand-as-Filesystem**: 将品牌、产品、素材和用户数据映射为虚拟文件系统, Agent 通过统一路径读取业务上下文; 实现品牌维度数据隔离与只读空间挂载, 按 Session 加载对应 Skill, 使同一引擎服务多品牌互不干扰。
- **人机协作模式**: 设计 Option Card 中断机制——Agent 在关键决策点暂停并向用户展示选项卡片, 用户选择后恢复执行; 实现 Ghost Messages 上下文注入, 在不增加用户可见消息的情况下向 Agent 补充系统指令和业务约束。
- **热点洞察与内容引擎**: 搭建每日热点采集→去重→分类→评分管线, 关联品牌类目提供查询接口; 集成多策略图片生成(DALL-E / Stable Diffusion / 字节 Seedance)与 MiniMax H3 视频生成, 支持从选题到素材的一站式内容产出。
- **跨渠道发布与追踪**: 对接 LinkedIn、Meta 等社交平台 API 实现内容自动分发; 基于 SignNoz + OpenTelemetry 构建前端→后端→LLM 全链路分布式追踪, etcd 动态配置热更新支持 Channel 亲和性路由与多模型无缝切换。

竞赛与开源

TAAC 2026 推广 CVR 预测竞赛 工业赛道 Top

基于 OneTrans 统一 Tokenizer + HyFormer 混合架构(Longer cross-attention 解码 + MLP-Mixer 特征交互), 通过 30+ 轮严格单变量消融验证 CVR 预测效果。核心方法: EDA 驱动信号量化筛选(Cohen's d > 0.2 进入实验), 时间周期编码 +0.26%, 噪声维度删除 +0.14%, batch_size 隐式正则化 +0.25%。AUC baseline 0.8411 → 0.8505 (+1.1%), 全程一次一变量可复现。

Apache Higress RAG 赛道 决赛入围

设计 Pre-Retrieval → 多路混合检索 → CRAG 纠错闭环全链路增强架构, 支持向量 + BM25 + WebSearch 多路检索与 RRF 融合, HotpotQA 数据集 EM=0.94(10,000 样本)。

Apache 开源贡献 Contributor

Apache Higress(云原生 API 网关)Contributor, 贡献 RAG 增强框架实现; Apache seata-go(分布式事务)Contributor, 修复 insert-on-duplicate 场景空值查询 bug, 添加 PR 自动化单元测试 CI。

专业技能

编程与后端	Go(主力)、Python、Java; SQL、Redis、Kafka、Kubernetes
模型工程	CTR/CVR 预估(OneTrans / HyFormer)、TensorFlow + Horovod 分布式训练、TFRA 动态 Embedding、Isotonic 校准、TensorFlow Serving
Agent 与检索	Agent 工具集设计与接入、向量检索 + BM25 + RRF + CRAG、工作流自动化
广告系统	RTB 竞价引擎、Bid Shading / 博弈定价、智能出价(PID / OCPC / Smart Bidding)、流量优先级与 RPM 限流、AB 实验设计

教育背景

天津财经大学 · 本科 · 2021.09 - 2025.06